개발 문서

온기(溫氣): 아이와 함께하는 부모의 일기 유산함



프로젝트 구분	2026 학년도 2 학기 모바일시스템응용프로젝트 (7 분반 5 팀)
프로젝트명	온기(溫氣)
팀명	AI 큐
작성일	2026-11-12
문서 버전	v1.2 (최종 시연본)
지도교수	정병덕 교수님
산업체 멘토	(주)마음 AI 김민선, 한하평 매니저
구성원	공지현(팀장), 박석준, 황정범, 서유정

2. 아키텍처 설계서

온기 시스템의 전체 구조와 구성 요소를 정의하고, 하드웨어와 소프트웨어가 어떻게 맞물려 동작하는지 밝힌다.

2.1 문서 개요

본 문서는 모바일 앱, 서버, 온기 디바이스 세 계층의 구조와 그 사이의 데이터 흐름을 다룬다. 모듈 사이의 호출 규격은 4 장, 모델에 대한 상세는 3 장에서 다룬다.

2.2 시스템 개요

설계 목표 및 원칙

1. 디바이스가 원본 보관소다. 부모 메시지는 디바이스에 저장되고, 서버가 없어져도 이미 받은 메시지는 재생된다.
2. 알아듣고 판단하고 들려주는 과정은 전부 디바이스 안에서 처리한다.
3. 상황은 키워드가 우선이다. 키워드와 임베딩이 상황을 정하고, LLM 이 한 번 더 확인하며 공감 한마디를 만든다. LLM 이 틀려도 키워드가 잡은 상황은 재생된다(판단 규칙 A).
4. 아이의 말은 서버로 보내지 않는다. 서버로 가는 것은 재생한 메시지와 시각뿐이다.
5. 제한된 자원에 맞춘다. LLM 은 NPU 에, STT·TTS·임베딩은 CPU 에 두고, 모두 디바이스 앱이 켜질 때 미리 올려 둔다.

디바이스를 따로 두는 이유

- 집에 놓인 유산함이다. 스마트폰은 몇 년마다 바뀌지만 디바이스는 부모의 메시지를 담은 채 한자리에 남는다.
- NPU 에서 LLM 을 돌린다. 판단과 공감에 쓰는 LLM 을 기기 안에서 실행하려면 전용 가속기가 있는 보드가 필요하다.
- 앱은 창구 역할만 한다. 앱이 없어도 디바이스에 저장된 메시지와 판단 기능은 그대로 유지된다.

계층	역할
모바일 앱	부모는 메시지를 남기고 관리한다. 자녀는 말하기를 시작하고 진행 상태와 들은 메시지를 본다
서버	부모가 남긴 메시지와 녹음 파일을 저장하고, 디바이스가 요청하면 전달한다
온기 디바이스	마이크로 들은 말을 인식하고, 상황을 판단하고, 공감 한마디와 부모 메시지를 스피커로 들려준다

2.3 하드웨어 아키텍처

구성 요소	역할
QCS6490 보드	음성 인식, 상황 판단, 음성 출력을 수행하는 본체
핀마이크 + USB 사운드카드	자녀의 발화 입력(48kHz 모노 녹음 후 16kHz 로 줄임)
미니 스피커	공감 한마디와 부모 메시지 출력(48kHz 스테레오)
공유기	앱, 디바이스, 서버 노트북을 같은 네트워크로 연결(ipTIME N604SR)

사운드카드는 보드가 부팅을 마친 뒤 보드 USB-A 에 직접 꽂는다. 꽂은 채 부팅하면 카드 번호가 바뀐다. 이 보드에서는 Android 앱 경로(AudioTrack·AudioRecord)로 USB 사운드카드를 쓸 수 없어(USB 오디오 오프로드), root 권한의 오디오 도우미가 tinyplay·tinycap 으로 하드웨어를 직접 쓴다. 앱은 요청 파일만 쓰고 도우미가 재생·녹음 결과를 남긴다.

연산	배치	이유
VAD, STT	CPU	연산량이 작다(STT 0.2 초 안팎)
임베딩(MiniLM int8)	CPU	모델이 작고 기준 문장 1,473 개와의 유사도 계산도 가볍다
LLM(Llama-3.2-1B)	NPU(HTP)	가장 무거운 연산이라 Genie 를 통해 NPU 에서 실행한다
TTS(VITS)	CPU	부모 메시지·연결 문장은 미리 만들고, 공감 한마디만 그때 만든다(0.3 초 안팎)

2.4 소프트웨어 아키텍처

레이어	구성	위치
앱 레이어	부모 화면, 자녀 화면과 상태 관리	모바일(Flutter)
서비스 레이어	메시지 API 와 저장 / 디바이스의 판단·재생 흐름	서버(FastAPI), 디바이스 앱(Kotlin)
모델 레이어	STT, TTS, 임베딩, LLM	디바이스 앱 안(Genie, sherpa-onnx, ONNX Runtime)
데이터 레이어	MySQL, 녹음 파일 / SQLite	서버 / 디바이스

디바이스 앱 모듈 구성(패키지 `com.aiq.ongi.device`)

모듈	역할
flow	전체 대화 흐름과 상태 전환. 듣기 → 받아쓰기 → 위기 → 판단 → LLM → 재생 규칙 → 소리 준비 → 신호·스피커
safety	위기 표현 규칙 검사
judge	키워드 판단(막는 말 포함), 임베딩 판단(기준 문장 비교), situations.json 읽기
ai_client	모델 호출을 한곳에 모음. Genie(LLM), SenseVoice·VITS(sherpa-onnx), MiniLM(ONNX Runtime), 오디오 변환(m4a 풀기, 48kHz 스테레오)
respond	LLM 답 해석, 판단 규칙 A, 공감 규칙 검사, 대체 공감
audio	root 오디오 도우미에 재생·녹음 요청, 마이크 말 끝 판단(silero VAD)
store	부모 메시지, 재생 기록, 동기화 상태(SQLite)
sync	30 초마다 서버에서 변경분을 받아 저장하고 재생 기록을 올림. 서버 주소가 바뀌면 처음부터 다시 받음
bridge	자녀 앱의 시작 요청을 받고 진행 상태를 알림(WebSocket 8765)
오디오 도우미	보드에서 root 로 도는 셸 스크립트. tinyplay·tinycap 으로 USB 사운드카드를 직접 사용



<그림 2-1> 온기 동작 흐름: 아이 말은 보드 안에서 판단하고, 서버와는 부모 메시지와 재생 기록만 오간다

아이의 말은 보드 안에서 받아쓰기부터 판단, 공감 한마디까지 끝나고, 서버와는 부모 메시지(30 초마다 동기화)와 재생 기록만 오간다.

재생 규칙

경우	처리
판단한 상황 = LLM 의 상황	생성 공감(규칙 통과 시) + 부모 메시지
키워드가 잡았는데 LLM 이 일반·다른 상황·형식 깨짐(판단 규칙 A)	키워드의 상황대로 대체 공감 + 부모 메시지
임베딩으로만 잡았고 LLM 과 다름	공감 한마디만
상황 없음 + LLM 일반 대화	받아주는 말
LLM 없음·시간 초과	판단한 상황대로 대체 공감 + 부모 메시지
그 상황에 부모 메시지 없음	생성 공감만(규칙 위반이면 받아주는 말)
여러 상황의 키워드가 걸림	생일(12) > 사건(2~6, 11) > 그리움(10) > 반응(1, 7~9)

2.5 데이터 아키텍처

저장소	위치	보관 내용	범위
SQLite	디바이스	부모 메시지(글, 녹음 파일 경로), 재생 기록(서버 전송 여부), 동기화 상태(since, 서버 주소, 서버 시각 보정값)	구현
모델·데이터 파일	디바이스	situations.json(상황, 키워드, 막는 말, 위기 표현), 기준 문장 벡터(1,473 개), 모델 파일	구현
설정 파일	디바이스	config.json(서버 주소, 아이 이름, LLM 설정). 빌드 없이 바꾼다	구현
MySQL	서버	가족, 상황 12 개, 부모 메시지(전달 여부, 삭제 표시), 재생 기록	구현
녹음 파일	서버	부모 녹음(m4a). 서버가 만든 임의 이름으로 저장	구현
AWS RDS·S3, IoT Core	서버	운영 환경의 DB·파일 저장과 실시간 전달	설계

처리 방식

- 음성 입력: 마이크 녹음을 0.1 초마다 읽어 말 끝을 판단하고, 발화 한 건 단위로 처리한다.
- 메시지 받기: 30 초마다 마지막으로 받은 서버 시각 이후의 변경분을 받는다. 삭제된 메시지는 녹음 파일까지 지운다. 서버와 한 번이라도 동기화한 뒤에는 시연용 기본 메시지를 다시 채우지 않는다.
- 미리 만들기: 부모 메시지(녹음은 풀고, 글은 TTS)와 연결 문장의 소리를 받을 때·앱을 켤 때 만들어 둔다.
- 재생 기록: 디바이스에 먼저 쌓고, 서버에 닿으면 보낸다. 보드는 시계가 따로 돌지 않아 서버 시각 보정값으로 재생 시각을 적는다.

데이터	디바이스 밖으로 나가는가	설명
아이의 음성	나가지 않음	받아쓰기가 끝나면 보관하지 않는다
아이의 발화 글	서버로 나가지 않음	화면 표시를 위해 같은 공유기 안의 자녀 앱에만 전달한다
재생 기록	메시지 ID 와 시각만 전송	발화 원문은 포함하지 않는다
부모 메시지	서버에서 디바이스로 전달	부모가 직접 등록한 내용이다

2.6 주요 기술 스택

영역	기술	범위
모바일 앱	Flutter(Dart), WebSocket, 녹음(m4a)	구현
서버	Python 3.13, FastAPI, PyMySQL, MySQL 8.0.16 이상	구현
디바이스 앱	Kotlin(Android 13), SQLite, Java-WebSocket	구현
통신	HTTP/REST(앱 ↔ 서버, 디바이스 ↔ 서버), WebSocket(자녀 앱 ↔ 디바이스)	구현
음성	silero VAD, SenseVoice STT, VITS TTS(sherpa-onnx 1.12.7, SUDA 앱과 같은 모델)	구현
오디오	tinyalsa(tinyplay·tinycap), root 도우미 스크립트, MediaCodec(m4a 풀기)	구현
임베딩	paraphrase-multilingual-MiniLM-L12-v2(384 차원), ONNX int8, onnxruntime-android 1.17.1	구현
LLM	Llama-3.2-1B-Instruct, Qualcomm Genie(QNN), SUDA 앱 라이브러리	구현
학습	PyTorch, Hugging Face Transformers·PEFT(LoRA), Google Colab T4	구현
배포	로컬 노트북 서버 + 공유기. AWS EC2·RDS·S3 는 시간이 남으면	구현 / 선택
운영 환경	AWS IoT Core(MQTT), 여러 가정, 로그인, HTTPS	설계
협업	GitHub 저장소 1 개(app/, server/, device/, ai/, docs/), Figma	-