개발 문서

온기(溫氣): 아이와 함께하는 부모의 일기 유산함

프로젝트 구분	2026 학년도 2 학기 모바일시스템응용프로젝트 (7 분반 5 팀)
프로젝트명	온기(溫氣)
팀명	AI 큐
작성일	2026-11-14
문서 버전	v1.2 (최종 시연본)
지도교수	정병덕 교수님
산업체 멘토	(주)마음 AI 한하평 팀장, 김민선 매니저
구성원	공지현(팀장), 박석준, 황정범, 서유정

3. 모델 설계 및 최적화 문서

QCS6490 환경에 맞는 AI 모델을 고르고, 데이터 구성과 학습, 경량화 전략을 정리해 디바이스에서 목표 성능을 확보하는 방법을 기록한다.

3.1 문서 개요

본 문서는 온기 디바이스에서 동작하는 모델 5 종과 그 데이터, 학습, 평가, 경량화 방법을 다룬다. 현재 학습 데이터 v3.7 을 확정하고 LLM 학습·병합·채점을 마쳐 양자화를 맡긴 상태이며, STT·TTS·임베딩은 보드에서 동작한다.

3.2 모델 선정 및 개요

역할	모델	구조	선정 이유
음성 구간 감지	silero VAD	경량 신경망	SUDA 앱과 같은 sherpa-onnx 스택에 포함
받아쓰기	SenseVoice	음성 인식 모델	한국어 지원, CPU 에서 0.2 초 안팎. SUDA 앱 모델을 그대로 쓴다
상황 판단(키워드 다음)	paraphrase-multilingual-MiniLM-L12-v2	Transformer 인코더(384 차원)	한국어를 포함한 다국어 모델이고 int8 로 줄여 CPU 에서 돈다
상황·기분 확인, 공감 생성	Llama-3.2-1B-Instruct	Transformer 디코더(LLM)	Genie 가 지원하는 공개 모델 중 작고, 짧은 형식의 출력은 안정적으로 학습된다
음성 합성	VITS(한국어 여성 화자 1 명, 22,050Hz)	음성 합성 모델	SUDA 앱과 같은 모델. 다른 TTS 는 찾지 않기로 했다

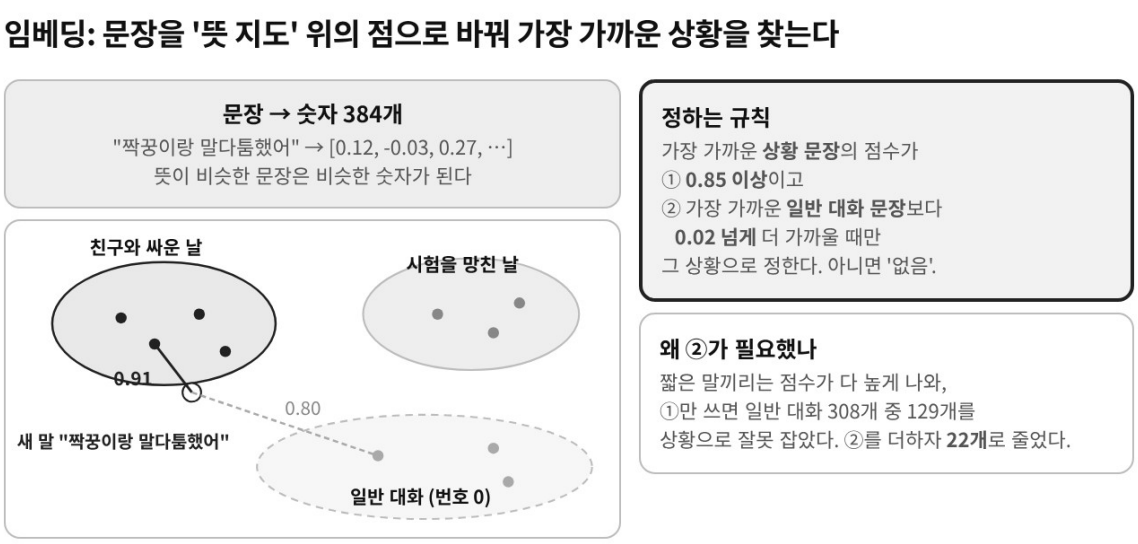
상황을 여러 방식으로 판단하는 이유

상황 판단은 잘못 재생을 막는 쪽을 우선한다. 키워드가 있는 말은 규칙으로 정하고, 막는 말로 남의 일과 다른 뜻을 걸러낸다. 키워드가 없는 말은 임베딩이 충분히 가까울 때만 정한다. LLM 은 문장 전체를 읽고 상황을 다시 고르며 공감 한마디를 만든다.

방식	장점	한계
키워드만	빠르고 판단 이유를 설명할 수 있다. 학습·평가 데이터에서 틀린 적이 없다	키워드가 없는 말을 놓친다
LLM 만	문장 전체의 뜻을 읽는다	1B 모델이 틀리면 막을 장치가 없고, 보드에서 돌지 않으면 판단이 멈춘다
키워드·임베딩 + LLM, 판단 규칙 A(채택)	키워드가 잡은 상황은 항상 재생되고, LLM 이 맞으면 아이 말에 맞는 공감이 나온다. LLM 없이도 동작한다	임베딩으로만 잡은 상황은 LLM 과 같아야 부모 메시지가 나온다

임베딩 판단은 이렇게 준비했다

키워드에 걸리지 않는 말(예: "짝꿍이랑 말다툼했어")은 임베딩으로 찾는다. 임베딩 모델은 문장을 숫자 384개로 바꾸는데, 뜻이 비슷한 문장은 비슷한 숫자가 된다. 이 숫자를 지도 위의 좌표처럼 생각하면, 새로 들은 말과 가장 가까이 있는 예시 문장의 상황이 곧 아이가 말한 상황이다.



그림은 이해를 돕기 위한 예시다(점수 값은 설명용). 실제 판단은 384차원에서 코사인 유사도로 계산한다.

<그림 3-1> 임베딩 판단: 새 말과 가장 가까운 예시 문장을 찾되, 일반 대화보다 확실히 가까울 때만 상황으로 정한다

임베딩 모델은 따로 학습하지 않았다. 공개된 다국어 모델을 그대로 쓰고, 어떤 예시 문장을 넣을지와 얼마나 가까워야 인정할지(기준값)로 성능을 맞췄다. 학습 없이도 예시 문장만 바꾸면 고칠 수 있고, LLM 이 없을 때도 시연이 돌아가는 바탕이 된다. 준비는 다음 순서로 했다.

단계	한 일	이유와 결과
1. 모델 고르기	paraphrase-multilingual-MiniLM-L12-v2(384 차원)를 골랐다	한국어를 지원하는 문장 비교 모델 중 작고 빠르다
2. 가볍게 만들기	Colab 에서 ONNX 로 바꾸고 int8 로 줄였다. 평균 내기와 길이 맞추기(정규화)까지 모델 안에 넣었다	보드 CPU 에서 바로 돈다(파일 118MB). 보드에서는 두 벡터의 곱만 하면 유사도가 나온다
3. 토크나이저 직접 만들기	문장을 조각으로 나누는 토크나이저 (SentencePiece Unigram)를 디바이스 앱 안에 직접 구현했다	변환 도구(onnxruntime-extensions)가 새 형식을 변환하지 못했다. 학습·평가 문장 전부에서 원래 토크나이저와 결과가 같은지 Colab 에서 확인했다
4. 예시 문장 미리 넣기	학습 데이터 v3.5.2 의 1,473 문장을 미리 벡터로 바꿔 파일로 넣었다(상황 1~12, 일반·불명확은 0 번)	말할 때마다 계산하지 않고 비교만 한다 (2.2MB)
5. 기준값 정하기	가장 가까운 상황 문장이 0.85 이상이고, 가장 가까운 일반 문장보다 0.02 넘게 가까울 때만 정한다	점수 하나만 보면 일반 대화 308 개 중 129 개를 잘못 잡았고, 차이 조건을 더하자 22 개로 줄었다
6. 확인	평가 문장으로 채점하고, 같은 문장이 PC 와 보드에서 같은 결과가 나오는지 비교했다	평가 상황 문장 96.6% 정답, 다른 상황으로 착각 1, 일반을 잘못 잡음 1(11/2)

12 개 상황을 그대로 둔 기준 문장과 시연 4 개 상황만 남긴 기준 문장을 비교했을 때 평가 상황 문장에서 둘 다 120/120 이어서, 나중에 상황을 늘리기 쉬운 12 개 구성을 유지했다(3.3 절).

LLM 입출력 형식

구분	내용
입력	`<|im_start|>` + 마음 AI 템플릿 + 아이 말 + `Response:` . 템플릿은 "Below is the query from the users, please choose the correct function and generate the parameters to call the function. Query: {발화}"
출력(상황 말하기)	`<maum_0>(situation=4, feeling=1)<maum_sep>`친구랑 싸워서 속상했구나`<maum_end>`
출력(일반 대화)	`<maum_1>()<maum_end>`
새 토큰	`<maum_0>` 128256, `<maum_1>` 128257, `<maum_sep>` 128258, `<maum_end>` 128259(vocab 128260). 멈춤 토큰은 `<maum_end>`와 `<|eot_id|>`

입력 앞머리 `<|im_start|>`는 보드의 SUDA 앱과 같게 맞춘 것이며, 학습·평가·보드 추론에서 똑같이 쓴다. 보드에서는 설정 파일로 빌드 없이 바꿀 수 있다. 상황 후보나 상황 이름은 입력에 넣지 않는다.

공감 한마디 규칙(학습 정답 작성과 보드 검사에 같이 쓴다)

- 한 문장, 띄어쓰기를 뺀 25 자 이내, 반말
- 한글과 공백만, 물음표 금지
- 조언·지시("~해 봐"), 약속("~할게") 금지
- 부모 호칭(엄마·아빠·부모님)은 아이 말에 같은 호칭이 있을 때만 허용
- 같은 문장은 학습 데이터에 3 번까지

생성 공감이 규칙을 어기면 시연 상황마다 3 개씩 미리 쓴 대체 공감(총 12 개, 학습 정답과 다른 문장)을 번갈아 쓴다. 받아주는 말과 안전 응답은 LLM 이 만들지 않는 고정 문장이다.

기분 번호	기분	공감 한마디 예시
1	슬픔·속상함	시험을 망쳐서 속상했구나
5	외로움·그리움	엄마가 많이 보고 싶구나
6	기쁨·뿌듯함	오늘 상을 받은 날이구나
-	상황 없음·일반 대화(받아주는 말)	그런 날도 있지, 이야기해 줘서 고마워

3.3 데이터셋 구성

학습 데이터는 **v3.7 로 확정**했다(11/5). 설계·키워드·임베딩은 12 개 상황을 유지하고, LLM 학습과 시연은 4 개 상황(3, 4, 10, 11)에 집중했다. 나머지 상황의 말과 남의 일·놀이 같은 경계 밖 문장은 일반 대화(`<maum_1>`)로 학습한다.

항목	값
학습 데이터	1,061 문장 = 원본 849 + 띄어쓰기 변형 212(음성 인식처럼 "친 구랑", "시험망쳤어". 내용과 정답은 그대로)

항목	값
평가 데이터	183 문장 = 상황 120(4 개 상황 각 30) + 일반 대화 63. 학습과 겹침 0
기분	상황마다 고정(시험 1, 친구 1, 보고 싶음 5, 자랑 6)
형식	마음 AI 학습 형식(No, 기능명, LLM Output, Query) CSV · JSON
키워드	12 개 상황, situations.json. 학습 데이터 상황 문장 745/745, 평가 120/120 을 맞힌다
임베딩 기준 문장	1,473 문장(v3.5.2, 12 개 상황 + 없음). 임계값 0.85, 없음과의 차이 0.02

작성 원칙

- 상황 문장은 사건 단어와 마음이 드러나는 내 일만 넣는다. 장소 · 이유 · 특정 인물 같은 변수는 빼고 정한 말만 쓴다(11/4).
- 책 · 만화를 보다 운 말처럼 애매한 말과 두 상황이 섞인 말은 학습 · 평가에서 뺀다.
- 문장부호, 이모티콘, 영어, 숫자를 넣지 않고 한글과 공백만 쓴다. 실제 입력이 음성 인식 결과이기 때문이다.
- 평가 문장은 학습에 없는 표현으로 쓰고, 처음 보는 말투에도 맞히는지 보려고 "있잖아", "~단 말이야" 같은 말투를 학습보다 많이 넣었다. 학습 데이터는 표지 없는 평범한 말이 46%, 평가 데이터는 30%다.
- 학습 데이터는 스크립트로만 만들고 검사한다. 키워드를 더할 때는 학습 · 평가 데이터의 판단이 바뀌지 않는지 먼저 확인한다.

12 개 상황을 그대로 두고 4 개로도 임베딩 기준 문장을 만들어 비교했지만, 평가 상황 문장에서 둘 다 120/120 으로 차이가 없어 12 개(v3.5.2) 기준을 유지했다.

3.4 모델 학습 및 평가 전략

학습하는 모델은 Llama-3.2-1B-Instruct 하나다. 새 토큰 4 개를 추가하고 `<maum_end>`를 멈춤 토큰으로 두어 위의 출력 형식을 학습시켰다. MiniLM 은 학습하지 않고 기준 문장과 임계값으로 조정한다.

항목	값
학습 환경	Google Colab T4 GPU. 멘토 GPU 를 받지 못해 팀이 직접 학습했다
베이스 모델	unsloth/Llama-3.2-1B-Instruct(Meta 원본과 같은 가중치, 허가 없이 받을 수 있는 사본)
학습 방식	LoRA r=16, 모든 선형층 + 새 토큰 4 개의 임베딩
Epoch / Batch / Learning Rate	3 / 8 / 2e-4
제출물	LoRA 를 베이스와 병합한 fp16 모델(2.47GB) + 토크나이저 + 학습 · 평가 데이터. 11/5 마음 AI 공유 폴더에 제출
채점 기준	형식(정해진 모양인가), 상황(상황 번호가 같은가), 일반(일반 대화를 일반으로 봤는가), 공감 규칙 위반

학습 결과(평가 183 문장, 병합 fp16)

항목	결과	목표
전체 정답	175/183(95.6%)	90% 이상

항목	결과	목표
상황 문장	113/120(94.2%)	95%
일반 대화	62/63(98.4%)	-
답 형식 깨짐	0	0%에 가까움

LoRA 와 병합 모델의 결과는 같았다. 틀린 8 문장 중 7 개는 상황을 일반으로 본 경우("있잖아 아빠 그립단 말이야" 등)이며, 보드에서는 키워드와 판단 규칙 A 가 받아 부모 메시지가 재생된다. 1 개는 남의 일을 상황으로 본 경우("형이 친구랑 싸웠대")로, 보드에서는 막는 말이 걸러낸다. 공감에 아이가 부른 호칭이 앞에 붙는 경우가 3 개("엄마 친구랑 싸웠구나") 있었고, 아이가 먼저 부른 호칭은 공감에 써도 된다는 규칙에 따라 그대로 둔다.

보드 평가: 마음 AI 가 양자화한 모델(w8a16, QNN 2.40)을 보드 NPU 에서 같은 평가 183 문장으로 채점했다(11/13). 171/183(93.4%)으로 Colab 보다 2.2%p 낮아 목표(3%p 이내)를 지켰고, 형식 깨짐은 0 이었다. 상황별로는 시험 28/30, 친구 24/30, 보고 싶음 27/30, 자랑 30/30, 일반 62/63 이다. 놓친 11 문장은 대부분 "~다뒀단 말이야", "있잖아 ~" 말투로, 보드에서는 키워드가 먼저 잡는다. 일반 대화를 상황으로 본 1 문장("형이 친구랑 싸웠대")은 Colab 과 같았고 막는 말이 거른다. 호칭이 앞에 붙은 공감은 2 개였다.

3.5 모델 경량화 및 최적화 방안

대상	기법	내용
Llama-3.2-1B	양자화·변환	(주)마음 AI 가 병합 fp16 모델을 양자화해 QNN context binary 와 Genie 설정 파일로 만든다
Llama-3.2-1B	입출력 길이 제한	보드 Genie 의 문맥은 128 토큰이다. 고정 부분 약 29 토큰 + 출력 최대 30 토큰을 빼고, 아이 말은 60 자로 자른다
Llama-3.2-1B	멈춤 토큰	Genie 설정의 eos 에 `<maum_end>`(128259)를 넣어 공감 문장 끝에서 바로 멈추게 한다
MiniLM	int8 ONNX	토크나이저(SentencePiece Unigram)는 앱에서 직접 구현하고, 모델은 int8 ONNX 로 줄여 CPU 에서 실행한다
전체	미리 올리기·미리 만들기	앱이 켜질 때 모든 모델을 올리고, 부모 메시지 소리를 미리 만든다(약 9 초)

가지치기와 지식 증류는 적용하지 않는다. 1B 모델은 양자화만으로 디바이스에 올릴 수 있는 크기다.

항목	목표	현재
전체 응답 시간	3 초 이내	4.0~5.1 초(양자화 LLM, 실제 마이크, 11/14)
LLM 시간	1 초 이내	2.7~3.6 초(공감 한마디 생성 포함)
양자화 전후 정확도 차이	3%p 이내	2.2%p(95.6% → 93.4%)

3.6 추론 엔진 및 런타임 환경

모델	추론 엔진	실행 장치	모델 형식
silero VAD	sherpa-onnx 1.12.7	CPU	ONNX

모델	추론 엔진	실행 장치	모델 형식
SenseVoice	sherpa-onnx 1.12.7	CPU	ONNX(int8)
MiniLM	onnxruntime-android 1.17.1	CPU	ONNX(int8)
Llama-3.2-1B	Qualcomm Genie(QNN 2.40)	NPU(HTP)	QNN context binary
VITS	sherpa-onnx 1.12.7	CPU	ONNX

모든 엔진은 디바이스 앱 안에 라이브러리로 들어 있다. sherpa-onnx 라이브러리는 보드에 들어 있던 SUDA 앱에서 가져왔다. Genie·QNN 라이브러리는 처음에 SUDA 앱의 2.28 을 쓰다가 양자화 모델에 맞춰 마음 AI 가 함께 준 2.40 으로 바꿨고(6.3 절), onnxruntime 버전은 sherpa-onnx 와 맞추려고 1.17.1 로 고정했다.