개발 문서

온기(溫氣): 아이와 함께하는 부모의 일기 유산함

프로젝트 구분	2026 학년도 2 학기 모바일시스템응용프로젝트 (7 분반 5 팀)
프로젝트명	온기(溫氣)
팀명	AI 큐
작성일	2026-11-14
문서 버전	v1.2 (최종 시연본)
지도교수	정병덕 교수님
산업체 멘토	(주)마음 AI 한하평 팀장, 김민선 매니저
구성원	공지현(팀장), 박석준, 황정범, 서유정

6. 배포 및 통합 가이드

개발한 모델과 앱을 QCS6490 디바이스에 올리고 앱, 서버와 연결하는 절차를 정리해, 팀원 누구나 같은 순서로 환경을 다시 만들 수 있게 한다.

6.1 문서 개요

본 문서는 디바이스 앱과 모델을 보드에 올리고, 서버와 앱을 연결하는 실제 절차와 겪은 문제를 다룬다. 각 파트의 README 만 보고 다른 팀원이 같은 결과를 낼 수 있어야 완료로 본다.

6.2 배포 환경 설정

항목	내용
대상 기기	Coretronic COREKOM R6490Q(QCS6490), Android 13 userdebug, adb root 가능, adb 시리얼 75ef63f(USB-C)
주변 장치	USB 사운드카드(보드 USB-A 에 직접), 핀마이크, 미니 스피커(USB 전원 별도), 공유기(보드는 가운데 랜 포트 ↔ 공유기 LAN 포트)
개발 PC	macOS, Android Studio(디바이스 앱 빌드·설치), adb(Android SDK 것만 사용), scrcpy(항상 `--no-audio`), Python 3 + websockets(점검 도구)
서버 PC	Python 3.13, MySQL 8.0.16 이상(개발 26.10), 가상환경 + requirements.txt, `uvicorn main:app --host 0.0.0.0 --port 8000`
LLM 학습	Google Colab T4, 학습·병합 노트북(ai/notebooks)

설정값

항목	위치	값
서버 주소(디바이스)	보드 `/data/local/tmp/ongi/config.json` 의 server_url	USB 개발: `http://127.0.0.1:8000`(adb reverse) / 공유기: `http://<서버 PC IP>:8000`. 빌드 없이 바꾸며 30 초 안에 반영
아이 이름	같은 파일의 child_name	민준
LLM 설정	같은 파일의 llm_config, llm_prefix, use_genie	Genie json 경로, `<|im_start|>`, true/false. 앱을 다시 켜면 적용
서버 주소(앱)	app/lib/config.dart	`http://<서버 PC IP>:8000`
디바이스 주소(앱)	app/lib/config.dart	`ws://<보드 IP>:8765`
DB 접속	server/.env	DB 주소, 계정, 비밀번호, 시간대 +09:00. GitHub 에 올리지 않는다

공유기에서는 주소가 자동으로 배정된다(11/7 보드 192.168.0.2). 고정 IP 를 쓰지 않을 때는 그날 서버 PC 의 IP 를 확인해 server_url 에 넣는다.

6.3 모델 및 추론 엔진 설치

모델	파일	보드 위치
SenseVoice, VITS	sherpa-onnx 용 ONNX 모델(STT 240MB, TTS 77MB, espeak-ng-data). SUDA 앱에서 꺼냄	`/data/local/tmp/ongi/speech/`
silero VAD	silero_vad.onnx	`/data/local/tmp/ongi/speech/vad/`
MiniLM	minilm_int8.onnx, vocab.tsv, 기준 문장 벡터(anchors)	앱 저장소 `files/models/`
Llama-3.2-1B(양자화)	context binary, tokenizer.json, Genie 설정 json, HTP 확장 설정 json	`/data/local/tmp/ongi/llm/<폴더>/`
라이브러리	libGenie, libQnnHtp 등(QNN 2.40, 마음 AI 제공), onnxruntime-android 1.17.1(Gradle)	디바이스 앱 안

양자화 모델 교체 절차

1. 마음 AI 에서 받은 파일 폴더를 교체 스크립트(`swap_llm.sh <폴더>`)에 넘긴다. 스크립트는 파일을 보드에 넣고, Genie json 안의 경로를 보드 폴더로 고친다.
2. tokenizer 의 새 토큰 4 개 번호(128256~128259)와 Genie 설정의 eos 에 `<maum_end>`가 있는지 점검한다.
3. 설정 파일에 llm_config 와 use_genie 를 적고 앱을 다시 켜, "Genie 준비 완료"와 두 문장 시험 결과를 확인한다.
4. 보드 LLM 평가(`llm_eval.py`, 평가 183 문장)와 시연 점검(`demo_check.py`)을 돌린다. 되돌릴 때는 `swap_llm.sh --back`.

우리 양자화 모델(QNN 2.40)은 앱 안 Genie 라이브러리(SUDA 앱에서 꺼낸 2.28)와 버전이 달라, 앱의 jniLibs 에 마음 AI 가 함께 준 2.40 라이브러리(libGenie, libQnnHtp, libQnnHtpV68Stub, libQnnSystem, libc++_shared)를 넣고 다시 빌드했다. NPU 쪽 파일(libQnnHtpV68Skel.so)은 모델 폴더에 두고, 앱이 모델을 읽기 전에 ADSP_LIBRARY_PATH 맨 앞에 그 폴더를 넣는다. 앱을 다시 설치한 뒤에는 start_board.sh 를 한 번 더 돌려 오디오 도우미를 다시 켠다(11/14 적용).

6.4 온디바이스 시스템 통합 방법

보드 켜는 순서

1. 맥과 보드를 USB-C 로 연결하고 보드 전원을 꽂는다(주황 불).
2. 1~2 분 뒤 초록 불(부팅 완료)이 켜지면 사운드카드를 보드 USB-A 에 꽂는다. 헤드폰 단자에 스피커, 마이크 단자에 핀마이크를 꽂고 스피커 USB 전원을 넣는다.
3. 공유기를 쓸 때는 보드 가운데 랜 포트와 공유기 LAN 포트를 연결한다.
4. 준비 스크립트(`start_board.sh`)를 돌린다. 보드 연결, root, 오디오 도우미, 모델 파일, 앱 다시 켜기, 포트, 준비 완료까지 한 번에 확인한다.
5. 시연 점검(`demo_check.py`)에서 9/9 를 확인한다.

재시작은 전원을 뽑고 10 초 뒤 다시 꽂는다(adb reboot 뒤에는 USB 재인식이 되지 않았다). 사운드카드를 다시 꽂거나 보드를 다시 켜면 준비 스크립트부터 다시 돌린다.

서버 연결

1. 서버 PC 에서 `uvicorn main:app --host 0.0.0.0 --port 8000` 으로 서버를 켠다. Windows 는 방화벽에서 8000 번을 허용한다.
2. 서버 PC 의 IP 를 확인하고 공유기 연결 시험(`lan_check.sh <서버 IP>`)을 돌린다. 보드 → 서버 접속, 서버 주소 변경, 동기화, 한 바퀴와 재생 기록까지 확인한다.
3. 서버 로그에서 API-11 → 12 → 13 → 14 순서를, DB 에서 전달된 표시를 확인한다.

앱이 없을 때는 서버의 시험 화면(`/docs`)이나 API 호출로 메시지를 등록·수정해 서버 → 디바이스 구간을 확인한다. 시연 전에는 시험 중 쌓인 서버 재생 기록을 지운다.

앱까지 이은 시연 구성

앱은 윈도우 PC 의 안드로이드 에뮬레이터에서, 서버와 보드 도구는 맥에서 돌린다(맥 에뮬레이터는 화면 그리기가 느렸다). 보드는 맥과 USB 하나로 연결해 서버 동기화(adb reverse)와 앱 신호(adb forward + 맥 중계)를 함께 주고받는다.



<그림 6-1> 시연 구성: 윈도우 에뮬레이터 — 같은 와이파이(학교는 휴대폰 핫스팟) — 맥(서버·중계) — USB — 보드

- 맥 창 1(서버): ~/ongi-server/server 에서 uvicorn main:app --host 0.0.0.0 --port 8000
- 맥 창 2(보드): ~/ongi 에서 bash device/tools/start_board.sh. 사운드카드는 보드 부팅이 끝난 뒤 꽂는다
- 맥 창 3(점검): python3 device/tools/demo_check.py
- 맥 창 4(중계): python3 device/tools/ws_relay.py
- 윈도우: C:\src\ongi\app 에서 에뮬레이터(Pixel_8)를 켜고 flutter run. 연결 주소는 앱 설정 > 연결 주소에서 바꾼다
- 튜토리얼을 다시 보려면 앱 설정 > 이 기기 처음 상태로(연결 주소와 서버 메시지는 남는다)

설정 및 구성 매개변수

매개변수	설명	값
키워드·막는 말·위기 표현	situations.json(앱 assets)	12 개 상황, 위기 표현 7 개
임베딩 임계값	이보다 낮은 유사도는 없음	0.85, 없음과의 차이 0.02
말 끝 판단	말 뒤 조용한 시간 / 말 없음 / 최대 녹음	0.8 초 / 5 초 / 8 초
LLM 기다리는 시간	넘으면 LLM 실패로 처리	8 초
아이 말 길이	LLM 입력으로 자르는 길이	60 자

매개변수	설명	값
메시지 확인 간격	디바이스가 서버에 요청하는 간격	30 초, 앱 시작 직후 1 회
오디오 형식	녹음 / 재생	48kHz 모노 → 16kHz / 48kHz 스테레오
녹음 파일	앱 녹음 → 보드 재생	m4a, 최대 10MB

6.5 에러 처리 및 트러블슈팅 가이드

구현하면서 실제로 겪은 문제다.

날짜	증상	원인	해결
11/12	튜토리얼이 다시 나오지 않음	앱을 다시 켜는 것만으로는 첫 설정 기록이 남아 있음	앱 설정 > 이 기기 처음 상태로
11/12	"서버에 연결할 수 없어요"	앱 연결 주소 기본값이 에뮬레이터용(10.0.2.2)	앱 설정에서 맥 IP 입력. 시연 PC 만 기본값을 맥 IP 로(커밋하지 않음)
11/12	시연 DB 스크립트 2 번째 줄 오류	situation 표에 recommended 칸이 없음	칸을 빼고 다시 실행
11/12	온기기록이 비어 있음	재생 11 초 만에 앱에서 stop	끝까지 듣기, 재생 중 확인 창 추가
11/9	부모 녹음이 보드에서 무음	에뮬레이터 마이크 꺼짐·볼륨 0	녹음 무음 검사 (check_audio.sh), 녹음 화면 소리 막대
11/9	윈도우 앱이 보드에 닿지 않음	보드는 기자재 공유기, PC 는 집 공유기	맥 중계(ws_relay, 8766)
11/9	웹 미리보기에서 역할 화면 오류	웹 디버그 컴파일러와 큰 아이콘 묶음	릴리스 모드로 실행
11/7	마이크로 말하기 전에 0.5 초 만에 "말 없음"	지난 녹음 파일을 새 녹음으로 읽음	녹음 요청 전에 지난 파일을 지움
11/7	보드가 공유기 서버에 닿지 않음	보드에 랜선이 없어 네트워크 주소가 없었음	보드 가운데 랜 포트 ↔ 공유기 LAN, 맥은 같은 공유기 와이파이
11/7	모델 교체 스크립트가 tokenizer 를 못 찾음	예제 모델은 json 만 폴더에 있고 파일은 다른 곳에 있음	같은 폴더에 없으면 json 에 적힌 원래 경로를 씀
11/5	STT·TTS 라이브러리 로드 실패(OrtGetApiBase)	onnxruntime 버전이 sherpa-onnx 와 다름	onnxruntime-android 를 1.17.1 로 맞춤
11/5	앱이 오디오 도우미를 " 꺼짐"으로 오판	도우미가 살아 있음 파일을 비우고 쓰는 순간에 앱이 읽음	임시 파일에 쓴 뒤 이름을 바꿈
11/5	첫 발화의 STT 가 3 초	첫 실행 때 모델 준비	앱을 켤 때 STT 를 한 번 미리 돌림 (0.1 초)
11/5	빌드는 되나 코드가 빠짐	Kotlin 한 줄 뒤에 붙인 `//` 설명이 나머지를 주석으로 만듦	설명은 윗줄에 씀
10/30	앱에서 소리가 안 나고 `write blocked`, 녹음은 멈춤	USB 오디오 오프로드로 Android 경로가 막힘	root 도우미가 tinyplay·tinycap 을 씀
10/30	소리가 맥에서 나옴	scrcpy 가 보드 소리를 가져감	항상 `scrcpy --no-audio`

날짜	증상	원인	해결
10/30	스피커에서 아무 소리가 없음	스피커 USB 전원이 헐거움	다시 꽂고 미세한 잡음으로 전원 확인
10/30	tinyplay `Error playing sample`	시험 파일이 모노	재생은 48kHz 스테레오로 변환
10/30	adb protocol fault 반복	brew adb 와 Android Studio adb 가 충돌	SDK platform-tools 를 PATH 앞에 둠
10/30	adb reboot 뒤 연결 안 됨	재부팅 후 USB 재인식 실패	전원을 뽑고 10 초 뒤 다시 꽂음
10/26	사운드카드 번호가 바뀜	꽂은 채 부팅하면 USB 가 0 번	부팅 후 꽂기로 통일, 도우미가 카드 번호를 매번 찾음
-	재생 기록 시각이 틀림	보드 시계가 켜질 때마다 2025 년으로 돌아감	서버 시각과의 차이로 보정

로그 확인 및 디버깅 방법

- 보드 로그는 `adb logcat -s ongi` 로 본다. 오디오 도우미 로그는 `/data/local/tmp/ongi/audio.log` 에 있다.
- 단계마다 받아쓴 글, 걸린 키워드, 임베딩 1 순위와 유사도, LLM 답, 적용한 재생 규칙, 단계별 시간("한 바퀴: 말 끝 → 공감 소리 준비 ○○ms")을 남긴다.
- 아이의 발화가 담긴 로그는 디바이스 안에서만 확인하고 서버로 보내지 않는다.

6.6 업데이트 및 유지보수 전략

대상	방식	설명
부모 메시지	자동	온라인일 때 디바이스가 서버에서 추가·수정·삭제를 받아 반영한다
서버 주소, 아이 이름, LLM 설정	설정 파일	config.json 을 바꾸면 빌드 없이 반영된다
키워드, 기준 문장	수동(앱 다시 설치)	situations.json 과 기준 문장 파일을 바꾼다. 바꾸기 전에 학습·평가 데이터의 판단이 바뀌지 않는지 확인한다
LLM	수동(파일 교체)	교체 스크립트로 파일을 바꾸고 보드 평가를 다시 돌린다
디바이스 앱, 모바일 앱, 서버	수동 설치	GitHub 에서 받아 다시 설치한다(디바이스는 Android Studio, 앱은 APK)

모델과 데이터의 무선(OTA) 업데이트는 설계 과제로 둔다.

대상	표기	예시
데이터셋	v + 번호. 바꾼 내용과 이유를 기록	v3.7
LLM 모델	데이터 버전 + 형태	ongi_llama3.2-1b_v3.7_merged
소스 코드	GitHub 저장소 1 개. 파트별 브랜치(app, server, device, ai)에서 작업하고 점검일에 main 에 합친다	-

부록 A. 상황 12 개 대응표

화면 이름, 데이터 번호, 표현 단서를 하나로 맞춘 기준표다. 부모가 고르는 상황과 AI 가 찾는 상황은 이 표의 12 개와 같아야 한다. 추천은 "추천 10 개 채우기"에 들어가는 상황이고, 시연은 11/26 시연 문장에 쓰는 상황이다.

번호	화면 이름	분류 / 허용 기분(기본)	표현 단서(사건 + 마음)	추천	시연
1	학교 가기 싫은 날	학교·공부 / 2, 3, 4 (기본 4)	학교·등교·개학 + 가기 싫다·쉬고 싶다·무섭다	●	
2	실수해서 혼났을 때	학교·공부 / 1, 2, 3 (기본 1)	(내가) 혼났다·야단·꾸중 + 속상·억울·무서움	●	
3	시험을 망친 날	학교·공부 / 1, 2, 3, 4 (기본 1)	시험·대회 결과 + 망쳤다·떨어졌다·점수 낮다	●	●
4	친구와 싸운 날	친구 / 1, 2 (기본 1)	친구·형제와(랑·하고) + 싸웠다·다퉜다·말다툼	●	●
5	친구가 날 싫어하는 것 같을 때	친구 / 1, 2, 3 (기본 1)	애들·친구들이 나를 + 빼고·무시·따돌림·뒷담	●	
6	남들과 비교될 때	친구 / 1, 2 (기본 1)	다들·친구·인스타 + 부럽다·비교·나만 없다		
7	울고 싶은 날	마음 / 1, 2 (기본 1)	(내가) 울고 싶다·울었다·눈물·울컥	●	
8	아무것도 하기 싫은 날	마음 / 2, 4 (기본 4)	(내가) 귀찮다·하기 싫다·지쳤다·힘이 없다	●	
9	잠이 안 오는 밤	마음 / 2, 3 (기본 3)	밤·잠 + 잠이 안 온다·못 자겠다·뒤척인다	●	
10	부모님이 보고 싶을 때	가족·특별한 날 / 5 (기본 5)	엄마·아빠·부모님 + 보고 싶다·그립다·목소리 듣고 싶다	●	●
11	자랑하고 싶은 날	가족·특별한 날 / 6 (기본 6)	상·일등·백 점·반장·합격·칭찬 + (내가) 받았다·했다	●	●
12	생일(내 생일만)	가족·특별한 날 / 5, 6 (기본 6)	(내) 생일 + 오늘·내일·축하·케이크·선물		

기분 번호는 1 슬픔·속상함, 2 화남·억울함, 3 불안·긴장, 4 지침·무기력, 5 외로움·그리움, 6 기쁨·뿌듯함, -1 말하지 않음이다. 24 개 상황에서 빠진 12 개는 정확도를 확보한 뒤 추가를 검토한다.